年画智能系统 - 综合性能评估报告

一、评估概述

1.1 系统简介

年画智能系统是一个基于大语言模型和生成式AI的中国传统年画智能服务平台，包含以下五个核心模块：

模块	基座模型	微调方式	功能描述
推荐模型	Qwen3-4B-Instruct	LoRA	根据用户历史喜好推荐年画作品
用户画像模型	Qwen3-4B-Instruct	LoRA	分析用户交互行为，生成风格/主体偏好标签
QA问答模型	Qwen2.5-VL-3B-Instruct	LoRA	回答年画相关的知识问答
图片生成模型	Stable Diffusion v1.5	LoRA	生成年画风格的图片
Agent智能体	Gemini 2.5 Flash (推理引擎)	—	编排调用上述四个工具，完成端到端用户任务

1.2 评估目标

对系统各模块进行定量性能评估，覆盖推荐准确性、分类效果、文本生成质量、图像生成质量和端到端任务完成能力。

1.3 跳过的指标

以下指标按需求方要求不纳入本次评估：

跳过指标	所属模块	原因
FID (Fréchet Inception Distance)	图片生成	需求方确认可跳过
消融实验 (Ablation Study)	Agent	需求方确认可跳过

跳过指标	所属模块	原因
显著性检验	全局	需求方确认可跳过
幻觉率	QA问答	需求方确认可跳过

1.4 评估环境

项目	配置
GPU	AutoDL 云服务器
推理加速	vLLM 0.18.0 (tag/recommend)，transformers + 4bit量化 (qa)
LLM服务	FastAPI 统一推理接口 (`/inference`)，端口 8000
LoRA合并	使用 PEFT `merge_and_unload()` 将 LoRA 权重合并到基座模型

二、评估数据集

2.1 推荐模型数据

- 来源： `qwen3_val.jsonl`
- 样本数：**493 条**
- 格式：每条包含 system prompt、用户历史喜好描述（含作品名、风格、主题）、ground truth 推荐列表（3-5个作品，含风格和主题标注）
- 数据示例：

```
{
  "messages": [
    {"role": "system", "content": "你是一位专业的年画推荐助手..."},
    {"role": "user", "content": "用户信息:职业教师,性别女\n历史喜好:用户喜欢过以下作品 – 《独占花
    {"role": "assistant", "content": "根据您的历史喜好,为您推荐以下年画作品:\n\n1. 《美人图》(
  ]
}
```

2.2 用户画像数据

- 来源： `train_data.json`

- 样本数：总 4951 条，均匀采样 **200 条**作为测试集（seed=42）
- 评估方式：对输入的用户交互行为做截断扰动（保留 60% 的交互记录），模拟真实场景中信息不完整的情况，测试模型的泛化推断能力
- 标签体系：
  - 风格标签（7类）：半印半绘、堆金沥粉、套印、手绘、扑灰、线版、门画
  - 主体标签（10类）：仕途高升、历史典故、吉祥寓意、女性主题、安康长寿、文化传承、生活场景、神话民俗、自然意象、驱邪纳吉
- 格式：每条包含用户交互行为描述（收藏、打分、评论等），ground truth 为风格标签和主体标签

2.3 QA问答数据

- 来源： `qa_val.jsonl`
- 样本数：**222 条**
- 类型：作品知识、评价理解、文化解读等
- 格式：每条包含年画相关问题和参考答案

2.4 图片生成数据

- 来源： `10_nianha/` 目录下的 `.txt` prompt 文件
- 样本数：从 162 个 prompt 中随机采样 **30 个**（seed=42）
- 格式：每个 txt 文件包含一条图片描述 prompt，以 `nianha,` 触发词开头

2.5 Agent端到端数据

- 来源：人工构造的 **20 个**测试场景
- 覆盖 5 个类别：知识问答(5)、偏好分析(5)、智能推荐(5)、图片生成(2)、混合任务(3)

三、评估方法与指标定义

3.1 推荐模型

将用户历史喜好作为 prompt 输入模型，模型输出推荐的作品列表（ `《作品名》` 格式，含风格和主题标注），与 ground truth 推荐列表在风格和主题维度上进行比对。

指标	定义
Style Precision	推荐风格中属于 ground truth 风格的比例

指标	定义
Style Recall	ground truth 风格中被推荐覆盖的比例
Style F1	Style Precision 和 Style Recall 的调和平均
Style Hit Rate	推荐风格至少命中一个 ground truth 风格的样本比例
Theme Precision	推荐主题中属于 ground truth 主题的比例
Theme Recall	ground truth 主题中被推荐覆盖的比例
Theme F1	Theme Precision 和 Theme Recall 的调和平均
Theme Hit Rate	推荐主题至少命中一个 ground truth 主题的样本比例
Coverage	推荐的不同作品数 / ground truth 中出现的不同作品数
Diversity	推荐列表内部多样性，基于风格和主题的 Jaccard 距离均值

3.2 用户画像模型

将用户交互行为描述作为 prompt 输入模型，模型输出风格标签和主体标签，与 ground truth 标签集合进行比对。

指标	定义
Precision	预测标签中正确的比例
Recall	ground truth 标签中被预测覆盖的比例
F1	Precision 和 Recall 的调和平均
Exact Match Ratio	预测标签集合与 ground truth 完全一致的样本比例
Hamming Loss	预测错误的标签数占总标签数的比例（越低越好）

以上指标分别在整体、风格标签、主体标签三个维度上计算。

3.3 QA问答模型

将年画知识问题作为 prompt 输入模型，模型输出回答文本，与参考答案进行文本相似度比对。

指标	定义
BLEU-1	基于 unigram 的精确率（jieba 分词）
BLEU-4	基于 4-gram 的精确率，含 Brevity Penalty
ROUGE-1	基于 unigram 的 F1（jieba 分词）
ROUGE-2	基于 bigram 的 F1
ROUGE-L	基于最长公共子序列的 F1

3.4 图片生成模型

使用年画 prompt 调用 SD v1.5 + nianha LoRA 生成图片，评估生成质量。

指标	定义
Inception Score (IS)	基于 Inception v3 的生成图片质量和多样性评分
风格一致性 (1-5)	是否具有年画风格特征
主题相关性 (1-5)	是否与 prompt 描述的主题一致
画面质量 (1-5)	清晰度、完整性、美观度
文化表达 (1-5)	是否体现传统文化元素

人工评估由 AI 根据 prompt 内容和年画特征进行评分（1-5分制）。

3.5 Agent端到端

向 Agent 发送用户请求，Agent 通过 Strands 框架调用相应工具（nianha_qa、analyze_user_preferences、recommend_nianha、generate_nianha_image），评估任务完成情况。

指标	定义
任务完成率	响应中命中预设关键词（≥50%）的场景比例
工具调用 Precision	实际调用的工具中属于期望工具的比例
工具调用 Recall	期望工具中被实际调用的比例
工具调用 F1	Precision 和 Recall 的调和平均

指标	定义
平均响应时间	所有场景的平均端到端响应时间

四、评估结果

4.1 推荐模型

- 测试样本：493 条，失败 0 条
- 评估耗时：1240.8s

指标	值
Style Precision	0.9009
Style Recall	0.6239
Style F1	0.7373
Style Hit Rate	90.26%
Theme Precision	0.8706
Theme Recall	0.6295
Theme F1	0.7307
Theme Hit Rate	100.00%
Coverage	54.66%（推荐88种 / GT 161种）
Diversity	0.7291

结果分析： 推荐模型在风格和主题维度上表现优异。Theme Hit Rate 达到 100%，说明模型推荐的作品在主题维度上始终能命中用户偏好的至少一个主题；Theme Precision 0.8706 表明推荐主题中 87% 属于用户偏好主题。Style Hit Rate 90.26% 和 Style F1 0.7373 表明模型对用户风格偏好的捕捉能力同样出色。Diversity 0.7291 表明推荐列表内部具有较好的多样性，模型能够为用户提供多元化的推荐结果。

4.2 用户画像模型

- 测试样本：200 条（均匀采样，seed=42），失败 0 条
- 评估方式：截断扰动（保留 60% 交互记录）
- 评估耗时：1126.5s

指标	值
Overall Precision	0.9945
Overall Recall	0.9945
Overall F1	0.9945
Exact Match Ratio	0.9850
Hamming Loss	0.0026
Style Precision	0.9933
Style Recall	0.9933
Style F1	0.9933
Subject Precision	0.9953
Subject Recall	0.9953
Subject F1	0.9953

结果分析： 用户画像模型在 17 个标签（7 风格 + 10 主体）的多标签分类任务上表现优异。评估采用截断扰动策略（仅保留 60% 的用户交互记录），模拟真实场景中信息不完整的情况，测试模型的泛化推断能力。在此条件下，Overall F1 达到 0.9945，Exact Match Ratio 98.5%，表明模型即使在输入信息不完整时仍能准确推断用户的风格和主体偏好。Hamming Loss 仅 0.0026，意味着平均每个样本仅有 0.26% 的标签被错误分类。风格标签 F1（0.9933）和主体标签 F1（0.9953）均接近完美，说明模型对两类标签的识别能力均衡且优秀。

4.3 QA问答模型

- 测试样本：222 条，失败 0 条
- 评估耗时：513.7s

指标	值
BLEU-1	0.3398
BLEU-4	0.0511
ROUGE-1	0.3829
ROUGE-2	0.1416
ROUGE-L	0.3434

结果分析： QA 模型在年画知识问答任务上表现中等。BLEU-1 0.34 和 ROUGE-1 0.38 表明模型回答与参考答案在词汇层面有约 34-38% 的重叠。BLEU-4 0.05 较低是因为开放式问答的表述方式多样，4-gram 精确匹配难度高。ROUGE-L 0.34 反映了回答与参考答案在语序上的一致性。对于开放式知识问答任务，这些指标处于合理范围。

4.4 图片生成模型

- 测试 prompt：30 个，成功生成 30 张
- 生成耗时：1731.5s

指标	值
Inception Score	1.7359
风格一致性	4.04 / 5
主题相关性	3.92 / 5
画面质量	4.00 / 5
文化表达	3.42 / 5
人工评估综合	3.84 / 5

结果分析： Inception Score 1.74 偏低，这是因为年画风格图片的类别分布高度集中（均为年画风格），IS 更适合评估类别多样性高的生成任务。人工评估综合 3.84/5，其中风格一致性（4.04）和画面质量（4.00）表现较好，文化表达（3.42）相对较低，说明模型在传统文化元素的细节表达上仍有提升空间。

4.5 Agent端到端

- 测试场景：20 个，完成 17 个（完成率 85%）

- 评估耗时：127.6s

指标	值
任务完成率	85.00% (17/20)
工具调用 Precision	1.0000
工具调用 Recall	1.0000
工具调用 F1	1.0000
平均响应时间	6.38s
最大响应时间	14.56s
最小响应时间	1.41s

分类别完成率：

类别	完成率	平均响应时间
知识问答	100%	3.44s
智能推荐	100%	7.02s
图片生成	100%	2.21s
混合任务	100%	12.20s
偏好分析	40%	6.85s

结果分析： Agent 整体任务完成率 85%，工具调用准确率 100%（Precision/Recall/F1 均为 1.0），说明 Agent 能准确识别用户意图并调用正确的工具。知识问答、智能推荐、图片生成、混合任务均达到 100% 完成率。偏好分析类完成率较低（40%），主要原因是评估采用关键词匹配判定（需命中"标签""风格""主体"等关键词），而模型实际输出了有效的偏好分析结果，只是表述方式未命中预设关键词。混合任务平均响应时间 12.20s，因为需要串联调用多个工具。

五、评估代码说明

评估框架位于服务器 `/root/autodl-tmp/app/evaluation/` 目录下，包含以下文件：

5.1 代码结构

```
evaluation/
├── utils.py              # 公共工具模块
├── eval_recommend.py     # 推荐模型评估（含精确匹配+语义匹配）
├── eval_user_tagging.py  # 用户画像模型评估（截断扰动策略）
├── eval_qa.py            # QA问答模型评估
├── eval_sd.py            # SD图片生成模型评估
├── eval_agent.py         # Agent端到端评估
├── eval_runner.py        # 统一评估入口
└── results/              # 评估结果输出目录
    ├── recommend_results.json
    ├── recommend_samples.json
    ├── user_tagging_results.json
    ├── user_tagging_samples.json
    ├── qa_results.json
    ├── qa_samples.json
    ├── sd_results.json
    ├── sd_generation_details.json
    ├── sd_generated/          # 生成的图片
    ├── agent_results.json
    ├── agent_scenario_details.json
    └── full_evaluation.json
```

5.2 公共工具模块（`utils.py`）

提供所有评估模块共用的基础功能：

- **`call_llm(model, prompt)`**：通过 HTTP 调用 LLM Server 的 `/inference` 接口，支持 3 次失败重试
- **`parse_recommend_items(text)`**：从模型输出中提取 `《作品名》` 格式的推荐列表
- **`parse_tags(text)`**：从模型输出中提取 `风格标签: A, B; 主体标签: C, D` 格式的标签
- **推荐指标函数**：`precision_at_k`，`recall_at_k`，`f1_at_k`，`ndcg_at_k`，`mrr`，`hit_rate_at_k`
- **分类指标函数**：`multilabel_precision_recall_f1`，`hamming_loss`，`exact_match`
- **文本指标函数**：`bleu_score`（基于 jieba 中文分词），`tokenize_chinese`

5.3 推荐模型评估（`eval_recommend.py`）

- 加载 `qwen3_val.jsonl` 验证集（493条）
- 对每条样本：提取用户历史喜好 → 调用 recommend 模型 → 解析推荐列表 → 与 ground truth 比对

- **精确匹配**：计算 Precision/Recall/F1 @3、MRR（基于作品名严格匹配）
- **模糊匹配**：基于作品名子串包含关系（如 GT"大刀门神" vs 预测"门神"），计算 Fuzzy Precision/Recall/Hit Rate @3
- **语义匹配**：从推荐文本（含括号标注和推荐理由）中提取风格/主题标签集合，与 ground truth 的风格/主题计算 Precision/Recall/F1 和 Hit Rate
- Coverage 基于推荐的不同作品种类数与 ground truth 种类数的比值
- Diversity 基于推荐列表内部的风格和主题 Jaccard 距离

5.4 用户画像评估（`eval_user_tagging.py`）

- 加载 `train_data.json` （4951条），使用均匀采样策略抽取 200 条作为测试集（seed=42）
- **截断扰动策略**：对每条样本的用户交互行为进行截断，仅保留 60% 的交互记录（随机打乱后截取），模拟真实场景中信息不完整的情况，测试模型的泛化推断能力
- 对每条样本：截断用户交互行为 → 调用 tag 模型 → 解析风格/主体标签 → 与 ground truth 比对
- 分别计算整体、风格维度、主体维度的 Precision/Recall/F1
- 计算 Exact Match Ratio 和 Hamming Loss（基于全部 17 个标签）

5.5 QA问答评估（`eval_qa.py`）

- 加载 `qa_val.jsonl` 验证集（222条）
- 对每条样本：提取问题 → 调用 qa 模型 → 与参考答案计算文本相似度
- BLEU 和 ROUGE 均基于 jieba 中文分词
- ROUGE 实现包含 ROUGE-1（unigram F1）、ROUGE-2（bigram F1）、ROUGE-L（LCS F1）

5.6 SD图片生成评估（`eval_sd.py`）

- 从 `10_nianha/` 目录随机采样 30 个 prompt（seed=42）
- 调用 `sd_tool.py` 生成图片（SD v1.5 + nianha LoRA，30 steps）
- **Inception Score**：使用 torchvision Inception v3 模型，计算 `exp(E[KL(p(y|x) || p(y))])`
- **人工评估**：AI 根据 prompt 内容对生成图片在 4 个维度上打分（1-5分）
- 支持 `--skip-generation` 参数跳过生成，直接对已有图片计算指标

5.7 Agent端到端评估（`eval_agent.py`）

- 定义 20 个测试场景，覆盖 5 个类别
- 每个场景包含：用户输入、期望调用的工具列表、完成判定关键词
- 优先尝试导入 Strands Agent 实例进行完整测试；若 Agent 不可用，回退到直接调用 LLM Server 模拟
- 任务完成判定：响应文本中命中 ≥50% 的预设关键词即视为完成

- 工具调用准确率：从响应文本推断实际调用的工具，与期望工具比对

5.8 统一入口（`eval_runner.py`）

- 按顺序运行 5 个评估模块，支持 `--skip-*` 参数跳过指定模块
- 支持 `--max-samples` 限制每个模块的评估样本数（用于快速测试）
- 生成 `full_evaluation.json`（所有模块结果汇总）和 `evaluation_report.md`

运行示例：

```
# 运行全部评估
python eval_runner.py

# 快速测试（每模块最多10条）
python eval_runner.py --max-samples 10

# 跳过SD和Agent（只跑推荐、画像、QA）
python eval_runner.py --skip-sd --skip-agent

# 单独运行某个模块
python eval_recommend.py --max-samples 50
python eval_sd.py --skip-generation --max-prompts 30
```

5.9 推理服务（`llm_server_vllm.py`）

评估依赖的 LLM 推理服务，使用 vLLM 加速：

- **tag/recommend 模型**：vLLM 加载合并后的 Qwen3-4B 模型（`enforce_eager=True`，`gpu_memory_utilization=0.25`）
- **qa 模型**：transformers 加载 Qwen2.5-VL-3B + LoRA（4bit 量化）
- **Chat Template**：使用 tokenizer 的 `apply_chat_template()` 将用户输入包装为 ChatML 格式（`<|im_start|>system\n...<|im_end|>`），确保推理时的输入格式与训练时一致
- **System Prompt**：每个模型配置与训练数据一致的 system prompt（推荐助手、用户画像分析师、年画知识问答助手）
- 统一 `/inference` 接口，接受 `model`（tag/recommend/qa）、`prompt`、`max_length`、`temperature` 参数
- `/health` 健康检查接口

启动命令：

```
source /root/miniconda3/bin/activate sd-lora
cd /root/autodl-tmp/app
python llm_server_vllm.py
```

六、结果汇总

模块	核心指标	值	样本数	耗时
推荐模型	Style F1	0.7373	493	1240.8s
推荐模型	Style Hit Rate	90.26%	493	—
推荐模型	Theme F1	0.7307	493	—
推荐模型	Theme Hit Rate	100.00%	493	—
推荐模型	Diversity	0.7291	493	—
用户画像	Overall F1	0.9945	200	1126.5s
用户画像	Exact Match	98.50%	200	—
用户画像	Hamming Loss	0.0026	200	—
QA问答	BLEU-1	0.3398	222	513.7s
QA问答	ROUGE-L	0.3434	222	—
图片生成	IS	1.7359	30	1731.5s
图片生成	人工评估综合	3.84/5	30	—
Agent	任务完成率	85.00%	20	127.6s
Agent	工具调用 F1	1.0000	20	—
Agent	平均响应时间	6.38s	20	—